

Предикторы гемолитической активности, растворимости и стабильности пептидов: аналитический обзор для оптимизации окна безопасности HC50/MIC50

Executive summary

Для вашей целевой функции

$$SW = \frac{HC_{50}}{MIC_{50}}$$

наиболее полезны модели, которые **количественно предсказывают HC50**, поскольку бинарный ответ «гемолитический / негемолитический» теряет именно ту информацию, которая определяет числитель SW. Среди опубликованных подходов такого типа наиболее релевантны **HemoPI2** — 1 926 пептидов с экспериментальным HC50, Pearson $r = 0.739$, $R^2 = 0.543$; **ConsAMPHemo** — Pearson $r = 0.809$; и **AmpLyze** — sequence-only deep-learning preprint с $r = 0.756$. HemoPI2 дополнительно предоставляет классификатор и открытое ПО; ConsAMPHemo публикует код и данные. ¹

Для первичного скрининга бинарные модели всё же полезны. HAPENN, HLPpred-Fuse, HemoNet, AMPDeer и более новый LysePred дают хорошие опубликованные результаты, однако показатели между статьями нельзя напрямую ранжировать: различаются отрицательные классы, пороги гемолиза, дублирование близких последовательностей, train/test splits и сами экспериментальные определения гемолитической активности. Особенно показателен HemoPI-1: его отрицательный класс составлен из случайных Swiss-Prot последовательностей, что делает задачу значительно легче и создаёт риск обучения модели распознавать общую мембранную/AMP-подобную природу пептида вместо специфической токсичности для эритроцитов. ²

Самый важный практический вывод для вашего конкурса — HC50 > 128 мкМ является правым цензурированием. Запись `>128` содержит информацию $HC_{50} > 128$, поэтому в собственном регрессоре её следует обучать censored likelihood / Tobit-like / accelerated-failure-time loss. Присваивание таким точкам значения ровно 128 систематически занижает безопасные пептиды и уничтожает сигнал выше конкурсного предела. Это особенно существенно, поскольку при одинаковом `HC50 > 128` ваш tie-break определяется MIC50.

Из конкурсных правил немедленно следуют нижние границы:

MIC50, мкМ	Если HC50 > 128 мкМ, то
16	$SW > 8$
8	$SW > 16$

MIC50, мкМ	Если HC50 > 128 мкМ, то
4	$SW > 32$
2	$SW > 64$
1	$SW > 128$

Следовательно, в области $HC50 > 128$ дальнейшее улучшение скрытого истинного HC50 почти не помогает наблюдаемому ранжированию команд; **уменьшение MIC50 становится главным различающим фактором**. Для выбора кандидатов я бы поэтому использовал лексикографическую схему: сначала высокая вероятность пройти фильтр активности $MIC \leq 16$ мкМ хотя бы на одном штамме, далее высокая вероятность $HC50 > 128$ мкМ, затем минимальный ожидаемый MIC50 по конкурсной процедуре.

Экспериментальная воспроизводимость здесь принципиальна. В литературе термин MHC/hemolytic concentration использовали для 5%, 10%, 50%, 100% гемолиза и даже для максимальной концентрации, при которой гемолиза ещё не видно. В систематическом исследовании hemolysis assay изменение вида эритроцитов давало до четырёхкратных различий эффекта, а выбор детергента для 100%-контроля — до 2.7 раза. Поэтому объединённая база без assay metadata имеет структурный label noise, который вполне сопоставим с разницей между хорошими конкурсными пептидами. ³

Для **растворимости** главным ограничением доступных ML-моделей является несовпадение endpoint. Например, MahLool показывает AUROC около 0.95 и accuracy 91.3% для коротких последовательностей, однако его 18 453 метки происходят из PROSO II и отражают успешность растворимого экспрессирования в *E. coli*, что лишь косвенно соответствует растворимости химически синтезированного AMP в конкретном буфере. Для вашей задачи предпочтительны физико-химические оценки типа CamSol/CamSol-PTM плюс прямое измерение максимальной растворимой концентрации именно в MIC- и hemolysis-буферах. ⁴

Для **стабильности** endpoint также необходимо фиксировать заранее: serum/plasma half-life, устойчивость к отдельным протеазам, стабильность в CAMHB, химическая стабильность и агрегация — разные задачи. PLifePred обучался всего на 261 пептиде; более поздняя работа Tan et al. собрала 3 415 исходных записей и после фильтрации сформировала пять специализированных наборов, показав, что вид организма и матрица критичны. Лучшие reported R^2 в этой работе составили 0.84–0.984, однако поднаборы остаются небольшими и требуют внешней проверки. ⁵

Итоговый приоритет для вашей конкретной задачи: direct HC50 regression с учётом >128 → модель MIC по каждому конкурсному штамму → assay-specific calibration → растворимость в реальных буферах → стабильность на временах, сопоставимых с MIC/hemolysis assay. Бинарные hemolysis predictors полезнее всего как дополнительный ансамблевый сигнал и средство выявления явно рискованных последовательностей.

Как конкурсная функция меняет постановку задачи

В обычной литературе по AMP гемолиз часто моделируется как бинарная классификация. Ваш критерий требует существенно более богатого представления: HC_{50} входит непосредственно в отношение с MIC50, а верхний предел >128 мкМ превращает задачу в регрессию с цензурированными наблюдениями. НемоPI2 и ConsAMPНемо относятся к немногочисленным

опубликованным моделям, где исследователи уже перешли от чистой классификации к количественному HC50. ⁶

Полезно работать в логарифмической шкале:

$$\log SW = \log HC_{50} - \log MIC_{50}.$$

Для AMP это удобно ещё и потому, что MIC обычно измеряется серийными разведениями, а вариации концентраций имеют мультипликативный характер. CLSI M07 и ISO 20776-1 рассматривают broth dilution / broth microdilution как референсные процедуры определения MIC; ISO отдельно подчёркивает, что MIC отражает активность препарата **при заданных условиях испытания**. EUCAST также использует broth microdilution и Mueller–Hinton-based среды в своих методических материалах. ⁷

Для гемолиза аналогичной универсальной стандартизации AMP-данных пока нет. HAPENN обнаружил, что исходная литература применяет несовместимые определения МНС, а работа по оптимизации hemolysis assay показала сильную зависимость результата от экспериментального протокола. ³

Оптимальный статистический target

Для собственной модели я бы хранил наблюдение HC50 в виде тройки

$$(y_i, c_i, \text{assay context}),$$

где $y_i = \log HC_{50}$ для точного измерения, а $c_i = 1$ означает правое цензурирование. Для конкурсного результата HC50 >128 модель знает лишь

$$\log HC_{50} > \log 128.$$

Если модель предсказывает распределение

$$Y = \log HC_{50} \sim \mathcal{N}(\mu, \sigma^2),$$

то вклад точного наблюдения может быть обычной Gaussian/Huber regression loss, а для >128 :

$$L_{\text{cens}} = -\log \left[1 - \Phi \left(\frac{\log 128 - \mu}{\sigma} \right) \right].$$

Такой подход использует каждое >128 как доказательство высокой безопасности и сохраняет возможность различать кандидатов по вероятности настоящего HC50 существенно выше 128.

Конкурсный фильтр тоже имеет смысл сделать отдельным prediction head:

$$P \left(\min_j MIC_j \leq 16 \mu M \right),$$

где j индексирует исследуемые штаммы. Затем для кандидатов, вероятно проходящих этот фильтр, рассчитывать distribution-aware оценку SW.

Есть ещё одна важная терминологическая проблема: **MIC, MIC50 как 50%-е подавление роста и MIC50 как медиана MIC по панели штаммов — разные величины**. Стандарты broth

microdilution относятся к MIC как к концентрации, определяемой по росту при заданных условиях. В собственной таблице данных стоит развести поля MIC_endpoint, MIC50_growth и MIC50_panel, даже если организаторы конкурса используют для окончательного score только один из них. ⁸

Что это означает для дизайна кандидатов

Для пептида с ожидаемым MIC50 = 8 мкМ переход HC50 с 64 до 128 мкМ повышает SW с 8 до 16. Если эксперимент уже даёт HC50 >128, наблюдаемый результат переходит в цензурированный режим; тогда по вашему tie-break снижение MIC50 с 8 до 4 мкМ имеет очевидную конкурсную ценность.

Поэтому кандидаты естественным образом распадаются на три области:

Область	Главный риск	Что оптимизировать
MIC >16 на всех штаммах	исключение из расчёта	прежде всего антибактериальную активность
MIC ≤16, HC50 <128	недостаточное SW	HC50 и MIC одновременно
MIC ≤16, HC50 >128	формальная неразличимость по гемолизу	прежде всего MIC50 и воспроизводимость результата >128

Для последней области модель должна оценивать **вероятность сохранения HC50 >128 при экспериментальном повторе**, поскольку один предельный результат на фоне assay noise значительно слабее серии воспроизводимых измерений. Сильная protocol dependence hemolysis assay делает такую calibration особенно важной. ⁹

Гемолитическая активность: механизмы, дескрипторы, измерения и модели

Гемолитическая активность AMP в значительной степени возникает из того же физического механизма, который делает многие AMP антибактериальными: амфифильная молекула связывается с мембраной, концентрируется на интерфейсе и при достаточной мембранной активности нарушает целостность билипидного слоя. Систематические SAR-исследования показывают сильную связь гемолиза с гидрофобностью, амфифильностью и структурой гидрофобной поверхности; в magainin-подобных сериях повышение гидрофобности сопровождалось усилением взаимодействия с фосфолипидными мембранами и гемолитической активности. ¹⁰

Основные физико-химические предикторы

Средняя гидрофобность — один из наиболее устойчивых признаков. Увеличение гидрофобной поверхности обычно облегчает проникновение пептида в мембраны эритроцитов. В HemoPI2 анализ данных также связал повышенную гемолитическую активность с гидрофобными остатками; HemoPI ещё в 2016 году обнаруживал повышенную представленность L, F, W и ряда K/L/W-содержащих мотивов среди гемолитических последовательностей. ¹¹

Гидрофобный момент и амфифильность описывают пространственное разделение полярной и неполярной поверхностей, особенно для α -спиральных АМР. Для мембранно-активных пептидов они часто информативнее одной средней hydrophobicity, поскольку два пептида с одинаковым составом могут иметь совершенно разное распределение гидрофобной поверхности. HAPENN поэтому включает hydrophobic moment, несколько шкал гидрофобности, membrane propensity и related descriptors в свой набор признаков. ¹²

Суммарный заряд, charge density и pI важны в сочетании с гидрофобностью. Катионность способствует первичному электростатическому взаимодействию многих АМР с мембранами, однако связь с гемолизом нелинейна: одинаковый net charge при разных Lys/Arg pattern, гидрофобности и вторичной структуре может приводить к различной селективности. НемоPI2 связывает комбинацию гидрофобных и положительно заряженных остатков с повышенным гемолизом, а HAPENN явно включает charge и charge density. ¹³

Ароматические остатки, прежде всего Trp и Phe, способны усиливать межфазное связывание с мембраной; НемоPI также обнаружил W/F-содержащие мотивы среди обогащённых гемолитических паттернов. ¹⁴

Длина, молекулярная масса, α -helical propensity, aromaticity, aliphatic index, Boman index, instability index, hydrophobic ratio, membrane propensity и N-/C-terminal composition регулярно используются в ML-моделях. HAPENN представляет один из наиболее полных классических наборов таких дескрипторов. ¹⁵

N-/C-концевые модификации, циклизация и нестандартные аминокислоты могут менять заряд, вторичную структуру, протеолиз и мембранное взаимодействие. Это является проблемой для многих benchmark-моделей: HAPENN ограничивал допустимые модификации преимущественно N-acetyl/C-amide, НемоPI2 после фильтрации моделировал натуральный аминокислотный алфавит и исключал короткие последовательности <6 аа. ¹⁶

У этих признаков **нет универсального безопасного cutoff**. Например, определённый net charge или hydrophobic moment не гарантирует HC50 >128 мкМ. Они полезнее как многомерный design space и как признаки для локального SAR вокруг близких последовательностей.

Измерение HC50 и источники вариабельности

В количественной постановке HC50 — концентрация, вызывающая 50%-й лизис эритроцитов. НемоPI2 использует именно такой endpoint и приводит значения к микромолярной концентрации. ¹⁷

Типичная процедура включает промытые эритроциты, инкубацию с серией концентраций пептида, центрифугирование и спектрофотометрическое определение высвободившегося гемоглобина относительно отрицательного и 100%-положительного контроля. В исследовании оптимизации использовали 1% washed erythrocytes, 60 минут при 37 °C; в представленных опытах оптическую плотность измеряли при 405 нм. Конкретная длина волны и другие детали зависят от протокола. ¹⁸

В базе для ML желательно обязательное сохранение:

```
RBC species → donor/pool → erythrocyte fraction/hematocrit → anticoagulant → wash/buffer → pH/osmolality → temperature → incubation time → peptide solvent
```

→ concentration series → positive control → optical endpoint → dose-response fit → HC50 + CI.

Причина практическая: исследование protocol sensitivity выявило до четырёхкратного изменения гемолитического эффекта в зависимости от вида крови и до 2.7-кратного различия расчётного гемолиза в зависимости от детергента положительного контроля. ¹⁹

HAPPENN дополнительно выявил фундаментальную проблему исторических наборов данных: в исходных публикациях МНС мог означать концентрацию при 5%, 10%, 50% или 100% гемолиза либо максимальную концентрацию без видимого гемолиза. Такие записи нельзя безоговорочно объединять как один количественный target HC50. ²⁰

Практический классификационный cutoff в HemoPI2 — HC50 ≤ 100 мкМ для гемолитического класса и > 100 мкМ для негемолитического. Это **порог конкретной модели**, а не стандарт hemolysis assay, и он не совпадает с вашим конкурсным рубежом 128 мкМ. ²¹

Сравнение основных моделей гемолиза

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия	
HemoPI	2016	SVM; AAC/DPC, positional binary profiles, motifs	HemoPI-1: 552 hemolytic + 552 random Swiss-Prot negatives; также HemoPI-2/3 для уровней гемолиза	HemoPI-1 до Acc 95.7%, MCC 0.91; HemoPI-2 ≈ 78%, MCC ≈ 0.56	Web/Java standalone; современный открытый репозиторий с ясной лицензией не идентифицированы	
HemoPred	2017	RF/DT/SVM; AAC, DPC, physicochemical features	HemoPI benchmark sets	На общих HemoPI задачах reported performance около Acc ≤ 78%, MCC ≤ 0.56	Web server; открытые веса/репо не подтверждены	
HAPPENN	2020	Dense NN; также SVM/RF baselines	3 738 peptides, 1 543 H / 2 195 NH; DBAASP + Hemolytik; RR90 nonredundant subset	CV Acc 85.66%, MCC 0.71, AUC 0.90; RR90 Acc 82.73%, MCC 0.65	Web implementation; полностью воспроизводимый repository с checkpoints не установлен	
HLPpred-Fuse	2020	54 base models → ExtraTrees fusion; SVM/RF/GB/ERT/ KNN/AdaBoost + 9 feature families	Independent HLP test: 663 HLP + 1 999 NH; high/low test 168+148	HLP/NH BACC 0.905, MCC 0.823, AUC 0.967; high/low AUC 0.869	Web server; verified open checkpoints not identified	

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия	Г
ML-guided non-hemolytic peptides, Plisson et al.	2020	Ensemble классических ML-классификаторов; 56 modAMP descriptors	HemoPI benchmark sets	HemoPI-1 final models около Acc 94.3%, MCC 0.89	GitHub , <code>.pk1</code> , Python 3.6/Jupyter, MIT	С У В С
HemoNet	2021	NN: SeqVec contextual embeddings + circular fingerprints модификаций	DBAASP + Hemolytik	ROC-AUC ≈ 0.88 в reported comparison	GitHub ; <code>weights.hdf</code> ; Python 3.6, conda/RDKit; лицензия в рассмотренном README не подтверждена	Х У Т P
AMPDeep	2022	ProtBERT-BFD + transfer learning from secretion + selective fine-tuning	XGBC-Hem, HLPpred-Fuse, RNN-Hem и combined dataset	XGBC-Hem AUC 0.9995/MCC 0.9731; HLPpred-Fuse benchmark AUC 0.9716/MCC 0.8324; RNN-Hem AUC 0.8723/MCC 0.5972	Полная переносимость зависит от PLM/checkpoints; в данном обзоре устойчивый официальный checkpoint repo не подтвержден	С З Н S K S
PeptideBERT	2023	ProtBERT, 12 attention heads / 12 hidden layers, task-specific fine-tuning	Hemolysis + solubility + non-fouling datasets	Авторы сообщают SOTA hemolysis performance на использованном benchmark	GitHub , MIT; <code>requirements.txt</code> , model/data dirs	К Д С У Т
HemoPI2	2025	RF/GB/XGB/SVR/ etc.; ProtBERT/ ESM2; RF+MERCI hybrid; quantitative regression	1 926 unique peptides с HC50; первоначально DBAASP 3 147 + Hemolytik 560 до фильтрации; classification 891 H / 1 035 NH	Hybrid classification AUC 0.921; regression $r = 0.739$, $R^2 = 0.543$	GitHub , GPL-3.0; <code>pip install hemopi2</code> ; Python 3, sklearn 1.3.1, torch/transformers/ ESM; model archive	Н Н С В Т
ConsAMPHemo	2025	Siamese/ contrastive GRU + AAindex/ BLOSUM62 + ProtBERT; regression XGBoost	Несколько benchmark classification sets; quantitative hemolysis data assembled for regression	Classification Acc 99.54%, 82.57%, 88.04% на 3 sets; HC50 PCC 0.809	GitHub ; trained-model/ data directories; Python 3.10/CUDA; явная repo license в просмотренной версии не указана	Л С P Д Н В Б

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия
AmpLyze	2025	ProtT5/ESM2 residue embeddings + global descriptors + cross-attention, log-cosh regression	Quantitative HC50 AMP dataset	PCC 0.756, MSE 0.987	На момент данного обзора надёжно идентифицированный официальный code/checkpoint repo отсутствует
LysePred	2026	Multi-scale CNN с kernels 2, 4, 8...32 residues	6 benchmarks: HemoPI-1/2/3, RNN-Hem, HLPpred-Fuse, AMP-Combined	В среднем +9.13% MCC и +3.65% ACC относительно second-best reported methods; MCC CV <6.92%	GitHub ; conda requirements.txt, train_repeat.sh; явная license/checkpoint release в root repo не видны

Главная статистическая ловушка хорошо видна уже по этой таблице. AUROC 0.95 на наборе с легко отличимыми отрицательными последовательностями не обязательно полезнее AUROC 0.88 на biologically hard negatives. HAPPENN прямо показал проблему random Swiss-Prot negatives, а современные работы всё чаще переходят к nonredundant/independent benchmarking. ³⁴

Опубликованные AUROC моделей гемолиза

[Открыть график AUROC в PNG](#)

На графике приведены headline/external-test AUROC для HAPPENN, HLPpred-Fuse, HemoNet и HemoPI2. Их следует читать как масштаб достижимой дискриминации внутри соответствующих исследований; datasets различаются. HAPPENN сообщает AUC около 0.90, HLPpred-Fuse 0.967 на своей independent HLP задаче, HemoNet около 0.88, HemoPI2 hybrid 0.921. ³⁵

Для вашего score более информативна следующая картина:

Корреляция direct-HC50 моделей

[Открыть график HC50 regression в PNG](#)

НемоPI2 сообщает $r = 0.739$, ConsAMPHemo $r = 0.809$, AmpLyze $r = 0.756$. Даже $r \approx 0.8$ оставляет существенный residual uncertainty, а метрики получены на разных split/datasets; поэтому эти результаты оправдывают ансамблевый prescreen, но ещё не дают оснований считать single-model predicted HC50 точным заменителем эксперимента. ¹

Растворимость: что действительно предсказывают существующие модели

Для вашего применения растворимость является прежде всего **функциональным ограничением измеримости**. Пептид должен оставаться молекулярно доступным при

концентрациях, необходимых и для MIC, и для проверки гемолиза вплоть до 128 мкМ. Если он выпадает в осадок, агрегирует или сильно сорбируется на пластике раньше этого уровня, полученное «низкое значение гемолиза» становится трудно интерпретируемым.

Условие минимальной экспериментальной растворимости легко пересчитывается:

$$C_{\text{mg/mL}} = C_{\mu\text{M}} \times MW_{\text{kDa}} \times 10^{-3}.$$

Например, для пептида с $MW = 2$ kDa концентрация 128 мкМ соответствует 0.256 mg/mL. Реальный stock должен быть выше конечной assay-концентрации на коэффициент разведения.

Основные дескрипторы

Для пептидов наиболее переносимыми sequence-level признаками являются net charge и pI, hydrophobicity, spatial distribution гидрофобных остатков, aromatic content, размер, hydrogen-bonding capacity и склонность к самоассоциации. CamSol формирует intrinsic solubility profile из комбинации гидрофобности, электростатического заряда и secondary-structure propensities; метод исходно валидировался для белковых вариантов и позже был расширен до modified amino acids в CamSol-PTM. ³⁶

Для **малых молекул** классический ESOL показывает другой набор физико-химических детерминантов: calculated logP, molecular weight, aromatic heavy-atom proportion и rotatable bonds входят среди основных признаков линейной модели. Оригинальная ESOL-модель была построена на 2 874 экспериментальных solubility records. ³⁷

AqSolDB предоставляет 9 982 уникальных малых молекул, собранных из девяти открытых наборов. Однако поздний анализ solubility datasets подчёркивает, что источники смешивают различные типы растворимости, состояние вещества и условия измерения, создавая серьёзную неоднородность labels. Именно поэтому small-molecule AqSolDB/ESOL не следует переносить на AMP как готовую модель; они полезны скорее как методологический reference для QSPR и quality control. ³⁸

Endpoint и единицы

Для количественной работы стоит различать:

$$S \text{ [mol/L]}, \quad \log S = \log_{10} S, \quad S \text{ [mg/mL]}$$

и хранить pH, buffer, ionic strength, temperature, incubation/equilibration time и способ отделения нерастворимой фазы. Heterogeneity именно этих условий является одной из главных причин сложности general-purpose solubility prediction. ³⁹

Универсального порога «растворимый пептид» для вашей задачи нет. **Операционным threshold** имеет смысл сделать способность образца давать воспроизводимый раствор при ≥ 128 мкМ в hemolysis medium и при необходимой stock concentration для MIC. Это будет намного ближе к конкурсному failure mode, чем protein-expression labels.

Модели растворимости

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия
CamSol	2015	Physics/sequence-based phenomenological score	Белковые mutation datasets; intrinsic/structure-corrected solubility	Валидирован по direction/magnitude изменений растворимости на protein variants	Academic CamSol server; условия коммерческого использования регулируются Cambridge/Vendruscolo group
CamSol-PTM	2023/24	Расширенный physicochemical CamSol для modified amino acids	>50 000 in-silico variants; экспериментальная validation на 37 variants трёх peptides в accepted version	Средняя Pearson correlation около 0.72 в опубликованной работе	Cambridge implementation; полного свободного model-weight repo формата ML checkpoint нет
MahLooL / Peptide Dashboard	2023	Bidirectional RNN	18 453 PROSO II sequences; 47.6% soluble / 52.4% insoluble; length 18–198	Для short peptides <50: AUROC $\approx$ 0.95, accuracy 91.3%	GitHub , GPL-3.0; browser/serverless model artifacts
PeptideBERT solubility head	2023	ProtBERT transformer fine-tuning	Peptide/property datasets использованной работы	Published comparative evaluation; модель входит в три task-specific heads	GitHub , MIT; <code>requirements.txt</code> , training scripts/model dirs
ESOL	2004	Multiple linear regression/QSPR	2 874 measured small-molecule solubilities	Классический quantitative logS baseline	Реализации доступны в cheminformatics ecosystem; оригинальная статья публикует уравнение

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия
AqSolDB	2019	Dataset, база для RF/GNN/QSPR	9 982 unique compounds, 9 public sources	Dataset benchmark, собственной единственной модели нет	GitHub , открытые CSV/2D descriptors

Для вашего проекта я бы придавал MahLool/PeptideBERT-solubility небольшой ансамблевый вес и гораздо больший вес простым assay-matched measurements: визуальная прозрачность, turbidity/OD, centrifugation + HPLC/UV concentration, при необходимости DLS. Особенно важно проверять растворимость **после внесения в конечную ионную среду**, поскольку растворимость stock solution в воде/DMSO не доказывает растворимость после dilution.

Стабильность: протеолиз, химическая деградация и assay stability

«Стабильность пептида» объединяет несколько независимых endpoint. Для терапевтических работ часто измеряют half-life в whole blood, serum или plasma. Для oral peptides используются SGF/SIF. Для вашего конкурса наиболее непосредственным endpoint является сохранение химически интактной и растворимой формы на протяжении MIC- и hemolysis-assay.

Наиболее известные предикторы

Главный mechanistic predictor **протеолитической стабильности** — наличие и доступность protease cleavage sites. Современная работа Tan et al. специально ввела enzymatic-cleavage features: потенциальные места разрезания, частоту и enzyme-specific patterns. Эти признаки добавляли биологическую информацию поверх обычных physicochemical descriptors; дальнейшее улучшение в их работе пришло от transfer learning. ⁴⁵

D-amino-acid substitutions являются хорошо подтверждённым способом повышения устойчивости к протеазам, хотя могут одновременно изменить secondary structure и AMP activity. В исследовании polybia-MPI D-enantiomer значительно повышал protease stability, тогда как отдельная D-Lys modification также меняла структуру и могла ухудшать антимикробную активность. ⁴⁶

Циклизация, truncation и terminal modifications тоже используются для снижения доступности proteolytic cleavage sites, однако их эффект зависит от конкретной последовательности и структуры. Обзоры structure-activity relationships AMP связывают конформационную жёсткость циклических пептидов с повышенной metabolic stability. ⁴⁷

Для **химической/физической стабильности** отдельными рисками остаются oxidation-sensitive residues, hydrolysis/deamidation, disulfide scrambling, aggregation и surface adsorption. Эти endpoint значительно хуже представлены в общедоступных peptide ML datasets, чем blood half-life.

Вид и матрица нельзя игнорировать

Tan et al. приводят показательную пару для одного и того же пептида SUPR: 1.92 h в mouse blood против 161.7 h в human blood. Авторы поэтому строили отдельные модели для human blood, mouse blood и mouse intestine, а также отдельно для natural и modified peptides. ⁴⁵

Исходно они собрали 3 415 half-life records: 2 200 из PEPlife, 112 из PepTherDia, 852 из THPdb и 251 из литературы; после фильтрации сформировали существенно меньшие high-quality subsets. Лучшие test R^2 были 0.84, 0.90, 0.984, 0.93 и 0.94 для пяти специализированных задач. Высокие цифры следует трактовать с учётом небольших наборов и необходимости независимой external validation. ⁴⁵

Модели стабильности

Название	Год	Тип модели	Данные	Метрики	Код / веса / лицензия	
PLifePred	2018	SVM/SMOreg + AAC/PaDEL chemical descriptors	261 peptides: 163 natural + 98 modified; experimental mammalian-blood half-life	Natural: $r = 0.743$ с 45 PaDEL descriptors; modified/combined model до $r = 0.692$	Web server; GitHub PLifePred существует, однако современная репродуктивность значительно слабее новых проектов	
Enzymatic cleavage + transfer learning	2024	Traditional ML → DNN/AlphaPeptDeep transfer learning + cleavage descriptors	3 415 raw → curated 5 species/organ/type datasets	Test $R^2 = 0.84, 0.90, 0.984, 0.93, 0.94$	В статье подробно описана методика; публичный полноценный checkpoint репо в проведённом поиске не идентифицирован	
ML_Peptide SGF/SIF	2020-е	Pretrained cheminformatics ML models from isomeric SMILES	Simulated gastric / intestinal fluid datasets	Repo ориентирован на pretrained prediction; headline metric следует брать из associated article	GitHub ; Python 3.7.7, sklearn 0.24.2, XGBoost 1.3.3, RDKit 2020.03.3, pandas 1.3.0, numpy 1.20.3; явная license в просмотренном root не указана	

С точки зрения вашего score serum half-life является **третьестепенным проху**, если эксперимент занимает десятки минут/несколько часов в буфере без значимой протеазной нагрузки. Гораздо полезнее поставить assay-specific test: LC-MS/HPLC parent fraction сразу после приготовления, после времени, соответствующего MIC incubation setup, и после hemolysis incubation; параллельно контролировать растворимость/агрегацию.

Данные, воспроизводимость и архитектура рабочего решения

Для гемолиза основными источниками, на которых реально обучались ведущие модели, остаются **DBAASP** и **Hemolytik**. HAPPENN собрал данные из обоих ресурсов; HemoPI2 также объединил DBAASP и Hemolytik с последующей очисткой и приведением HC50 к общим единицам. В 2026 году появился обновлённый Hemolytik 2.0, что делает повторную curated extraction особенно перспективной для нового benchmark. ⁵¹

Для half-life база PEPlife исторически использовалась PLifePred, а обновлённая PEPlife2 появилась в 2026 году. ⁵²

Основные наборы данных


Название	Год	Тип / endpoint	Данные	Размер / баланс	Доступ	Ключевое ограничение
HemoPI-1	2016	Binary hemolysis	Hemolytik positives + random Swiss-Prot negatives	552 + 552	HemoPI datasets/ server	Random negatives делают benchmark искусственно лёгким. ⁵³
HemoPI-2	2016	High vs lower hemolytic potential	Experimental peptide classes	442 high + 370 known lower/ non main set	HemoPI	Label зависит от heterogeneous MHC definitions. ⁵⁴
HemoPI-3	2016	High vs low/ non hemolysis	Experimental peptide classes	708 high + 590 low/non main set	HemoPI	Аналогичная threshold heterogeneity. ⁵⁵
HAPPENN	2020	Binary hemolysis	DBAASP + Hemolytik	3 738: 1 543 H / 2 195 NH	Article/ server	Отдельный RR90 вариант уменьшает sequence redundancy. ⁵⁶
HemoPI2 quantitative	2025	HC50 regression + classification	DBAASP + Hemolytik	1 926 unique; binary representation 891 H / 1 035 NH	Article + GitHub/ web server	Natural-AA/ filter bias; mixed experimental protocols. ⁵⁷

Название	Год	Тип / endpoint	Данные	Размер / баланс	Доступ	Ключевое ограничение
PROSO-II-derived MahLooL	2023 model	Soluble expression	E. coli protein/peptide expression labels	18 453; 47.6% positive / 52.4% negative	Peptide Dashboard	Endpoint mismatch с aqueous synthetic-peptide solubility. ⁵⁸
AqSolDB	2019	Small-molecule aqueous logS	9 open sources	9 982 unique compounds	GitHub / Scientific Data	Heterogeneous measurement conditions. ³⁸
PLifePred/PEPlife subset	2018	Mammalian-blood half-life	Natural + modified peptides	261	PLOS/web	Очень малый и heterogeneous historical set. ⁵⁹
Tan et al. half-life corpus	2024	Species-/organ-specific half-life	PEPlife, PepTherDia, THPdb, literature	3 415 raw records, затем 5 curated subsets	Article	Мало данных в каждом конкретном biological domain. ⁴⁵

ChEMBL и PubChem разумно использовать как дополнительные источники assay records и cross-reference химических сущностей, PDB — как источник структурной информации для пептидов, имеющих экспериментальную структуру. Для обучения именно **HC50 in RBC** центральная задача всё равно состоит в извлечении и гармонизации endpoint из peptide-specific sources и первичных статей.


Минимальная схема данных

Нынешняя литература фактически требует хранить assay conditions как first-class entities. Такая схема позволит избежать смешивания человеческих и животных RBC, разных определений hemolysis, разных штаммов и сред.



Такая структура непосредственно адресует проблемы, выявленные HAPPENN и экспериментальной работой по стандартизации hemolysis assay, где различия определения endpoint и условий создают сильную неоднородность labels. 60

Развитие моделей



Хронология отражает переход от ручных physicochemical descriptors и SVM/RF к protein-language-model representations и, наиболее важно для вашей задачи, к количественным HC50 regressors начиная с HemoPI2/ConsAMPHemo/AmpLyze. В 2026 году classification направление продолжилось LysePred, параллельно обновились curated data resources. 61

Воспроизведение наиболее полезных открытых моделей

Модель	Репозиторий	Вес / формат	Среда	Минимальная процедура воспроизведения
HemoPI2	raghavagps/HemoPI2	Model bundle распространяется с standalone/package resources; сериализация зависит от submodel	Python 3; <code>scikit-learn==1.3.1</code> , pandas/numpy; torch/transformers/ ESM для PLM variants	Зафиксировать commit → создать clean venv/conda → установить <code>hemopi2 / requirements</code> → скачать model bundle, указанный репо → прогнать supplied example → отдельно проверить regression output на benchmark rows. ⁶²
ConsAMPHemo	Cpillar/ConsAMPHemo	Repo содержит dataset/model directories; единый checkpoint extension README явно не стандартизует	Python 3.10; PyTorch/ Transformers; GPU/ CUDA рекомендуется	Clone → environment из README/ requirements → получить ProtBERT dependency → <code>train.py</code> для training либо supplied model path для evaluation → проверить dataset splits. Явной лицензии в просмотренной версии репо нет. ⁶³
Plisson et al.	plissonf/ML-guided-discovery-and-design-of-non-hemolytic-peptides	<code>.pk1</code> classifiers	Python 3.6+, Jupyter, modIAMP/scikit stack	Clone → environment → запустить notebooks descriptor generation → загрузить 9 supplied <code>.pk1</code> models → повторить HemoPI predictions. MIT. ⁶⁴

Модель	Репозиторий	Вес / формат	Среда	Минимальная процедура воспроизведения
HemoNet	GitHub repo, связанный с HemoNet	<code>weights.hdf</code>	Python 3.6; conda; RDKit + sequence embedding dependencies	Установить environment → скачать <code>weights.hdf</code> по указанному авторами resource → воспроизвести sequence/terminal-SMILES preprocessing → inference. ²⁷
PeptideBERT	ChakradharG/PeptideBERT	Model directories/ checkpoints; HuggingFace/ PyTorch ecosystem	Python environment по <code>requirements.txt</code>	Clone → install requirements → download/use supplied data → split/ augmentation scripts → configure task → <code>train.py</code> ; tutorial используется для inference. MIT. ⁶⁵
MahLooL	ur-whitelab/peptide-dashboard	Browser-deployable model artifacts в <code>models/*</code>	Основной deployment serverless/browser	Clone static dashboard → использовать <code>sol-rnn</code> model assets либо project notebook/CLI → сверить outputs с web implementation. GPL-3.0. ⁶⁶
LysePred	lincubator/LysePred	Repo ориентирован на retraining; отдельный released trained checkpoint в README не заявлен	Conda requirements; CUDA 11.3 в исходной конфигурации	<code>conda create --name LysePred --file requirements.txt</code> → перейти к training entry в <code>main</code> → <code>train_repeat.sh</code> → результаты по умолчанию в <code>\$HOME/data/results</code> . Явная license в root listing не показана. ⁶⁷

Модель	Репозиторий	Вес / формат	Среда	Минимальная процедура воспроизведения
ML_Peptide SGF/SIF	FrankWanger/ML_Peptide	Pretrained SGF/SIF model directories	Python 3.7.7; sklearn 0.24.2; XGBoost 1.3.3; RDKit 2020.03.3.0	Подготовить isomeric SMILES → заполнить supplied CSV → выполнить prediction notebook → читать <code>Stability_in_SIF/SGF</code> . ⁵⁰

Для строгой воспроизводимости одного `requirements.txt` недостаточно. Я рекомендую сохранять git commit SHA, SHA256 модельных файлов, Python/CUDA versions, tokenizer/PLM revision, полный test split и raw-to-clean dataset mapping. Для HemoPI2/ConsAMP Hemo особенно важно воспроизвести **cam preprocessing HC50**, поскольку единицы и обработка ranges непосредственно воздействуют на ваш target. HemoPI2, например, переводил значения HC50 в общую микромолярную шкалу и усреднял определённые multiple/range entries при построении curated set. ²¹

Пробелы литературы и рекомендуемая стратегия для вашей задачи

Самый большой пробел — отсутствие крупного, assay-standardized набора **точных dose-response HC50 с явными right-censored values**, где одновременно известны MIC для фиксированной панели штаммов, растворимость и экспериментальные условия. HemoPI2 с 1 926 quantitative peptides является большим шагом вперёд, однако он всё ещё объединяет данные из различных источников и ограничивает химическое пространство после sequence filtering. ¹⁷

Второй пробел — **benchmark leakage и similarity bias**. HemoPI-1 показывает крайний случай с random negative proteins; HAPENN специально вводил RR90 dataset, чтобы уменьшить sequence redundancy. Для своей валидации я бы использовал clustered split с identity существенно ниже 90%, отдельный scaffold/family split и, по возможности, leave-publication/laboratory-out test. Последний особенно важен при сильном laboratory effect hemolysis assay. ⁶⁸

Третий пробел — **mismatch threshold**. Большинство classifier papers решают собственный бинарный endpoint; HemoPI2 использует 100 мкМ, ваш конкурс использует наблюдаемое цензурирование при 128 мкМ. Поэтому даже качественно calibrated 100-μM classifier имеет слепую область, критичную для вашего score. ²¹

Четвёртый пробел — химические модификации. Большая часть sequence-only benchmarks лучше покрывает canonical peptides, тогда как D-residues, cyclization, N/C modifications и другие изменения могут одновременно менять HC50, MIC, solubility и proteolytic stability. HemoNet является интересным исключением, поскольку пытается включать fingerprints концевых химических модификаций; CamSol-PTM аналогично расширяет solubility modelling на modified amino acids. ⁶⁹

Рекомендуемый prediction stack

Для вашего конкурса оптимальным выглядит ансамбль из четырёх уровней.

Уровень HC50. Использовать HemoPI2 + ConsAMPHemo как внешние quantitative baselines и обучить локальный censored HC50 model на curated DBAASP/Hemolytik2 с максимальным соответствием организаторскому assay. HemoPI2 даёт воспроизводимый классический/PLM baseline, ConsAMPHemo — независимый современный regression signal. ⁶

В качестве собственного sequence representation разумно сравнить три варианта: engineered descriptors; frozen ESM/ProtT5 embeddings + XGBoost/MLP; fine-tuned PLM. При объёме порядка нескольких тысяч quantitative observations простой boosted-tree head на PLM embeddings часто является более контролируемой отправной точкой, чем полный end-to-end fine-tuning. Финальный выбор следует делать по clustered external split, а не по random CV.

Уровень MIC. Обучать отдельные heads по каждому штамму. Универсальный AMP/non-AMP classifier недостаточно соответствует вашему score: организаторы используют конкретные штаммы и threshold 16 мкМ. В raw table необходимо хранить medium, inoculum/protocol, incubation и concentration grid в соответствии с принципом стандартизованного broth microdilution; CLSI, ISO и EUCAST подчёркивают dependence MIC от test conditions. ⁷⁰

Уровень developability. Использовать net charge, hydrophobicity, hydrophobic moment, aromatic fraction, pI, aggregation propensity и CamSol-like score как inexpensive filters; MahLooL/PeptideBERT-solubility можно включить как weak priors. Финальное решение о растворимости должно опираться на измерения в конкретных assay media, поскольку MahLooL обучен на soluble-expression endpoint. ⁷¹

Уровень stability. Для обычных all-L linear peptides полезны cleavage-site descriptors и PLifePred/Tan-like features. При наличии D-residues/cyclization требуется chemical representation, поскольку обычная protein-language-model строка теряет часть химии. Публикации подтверждают сильное влияние D-substitution на proteolysis, а modern half-life modelling подтверждает полезность cleavage features. ⁷²

Как я бы валидировал модель перед использованием для отбора

Основной quantitative benchmark должен измерять одновременно:

$$RMSE(\log HC50), \quad MAE(\log HC50), \quad Pearson\ r, \quad Spearman\ \rho$$

на exact observations, плюс отдельные censored metrics: concordance index и calibration

$$P(HC50 > 128).$$

Для конкурса особенно важна метрика **pairwise ranking accuracy именно среди пептидов с MIC ≤ 16**, поскольку это максимально близко к фактической функции ранжирования.

Я бы дополнительно рассчитывал:

$$\Delta \log SW = (\log HC_{50}^{pred} - \log MIC_{50}^{pred}) - (\log HC_{50}^{obs} - \log MIC_{50}^{obs})$$

и отдельную accuracy определения победителя для каждой пары кандидатов.

При двукратной сетке MIC даже сдвиг на одно разведение меняет знаменатель в два раза; аналогичная ошибка HC50 в противоположную сторону способна дать многократную ошибку SW. Поэтому модель с красивым global Pearson *r* может плохо ранжировать близких финалистов.

Именно здесь uncertainty intervals и assay-matched calibration ценнее небольшого улучшения среднего AUROC.

Практическая функция отбора

До получения экспериментальных результатов я бы рассчитывал для каждого кандидата как минимум:

$$P_{\text{active}} = P(\exists j : MIC_j \leq 16)$$

$$P_{\text{safe}} = P(HC50 > 128)$$

и conditional expected safety window

$$E \left[\frac{HC50}{MIC50} \mid \text{sequence, assay} \right].$$

Затем использовать последовательность решений:

1. оставлять кандидаты с высокой P_{active} ;
2. среди них максимально повышать P_{safe} ;
3. среди кандидатов с высоким P_{safe} минимизировать predicted MIC50;
4. штрафовать высокую predictive uncertainty;
5. сохранять physicochemical diversity, чтобы несколько финальных кандидатов не являлись практически одним sequence scaffold.

Последний пункт защищает экспериментальную программу от correlated model error: если весь top-10 состоит из близких аналогов, ошибка модели или неожиданный assay effect может одновременно затронуть весь набор.

Какой design region выглядит наиболее перспективным

Литература в совокупности указывает на поиск **умеренно катионных, достаточно амфифильных AMP с контролируемой гидрофобной поверхностью**, избегая чрезмерного увеличения hydrophobicity/amphipathic membrane-disruption signal. Гидрофобность является одним из наиболее последовательных гемолитических predictors, при этом antibacterial activity также зависит от мембранного взаимодействия; поэтому задача имеет настоящий Pareto frontier.

73

В локальной оптимизации лучше изменять отдельные позиции и отслеживать одновременно

$$\Delta \log MIC, \quad \Delta \log HC50, \quad \Delta \log SW,$$

чем оптимизировать отдельный hemolysis classifier score. Особенно полезны residue-attribution методы современных моделей как генераторы гипотез, после чего каждое изменение следует проверять более простыми physicochemical descriptors и локальными matched-pair данными. AmpLyze, например, специально использует Expected-Gradients residue attribution, а HemoPI2 анализирует sequence/feature associations.

74

Приоритет первоисточников

Для вашей задачи я бы расставил литературу по практической ценности следующим образом. В **первую группу** входят HemoPI2 и ConsAMPHemo как direct-HC50 models, HAPPENN как ключевая статья по bias/assay heterogeneity и работа по оптимизации экспериментального hemolysis assay.

75

Во **вторую группу** входят HLPpred-Fuse, HemoNet, AMPDeep, LysePred и исходный HemoPI как сильные classification/representation references.

76

Для **растворимости** приоритетны CamSol/CamSol-PTM для механистического reasoning и Ansari & White/MahLool как современный sequence model с обязательной оговоркой об E. coli expression endpoint. Для small-molecule контекста наиболее полезны исходный ESOL и curated AqSolDB.

77

Для **стабильности** исходной точкой остаётся PLifePred, а более современным методологическим ориентиром является работа Tan et al. с species-/organ-specific моделированием, cleavage descriptors и transfer learning.

5

В терминах именно вашего правила $SW = HC50/MIC50$ наиболее перспективный дальнейший исследовательский объект выглядит как **joint, assay-conditioned, censor-aware модель HC50 + strain-specific MIC**, обученная на очищенных quantitative records и валидированная на sequence-clustered external test. Это напрямую совпадает с целевой функцией конкурса, корректно использует $HC50 > 128$, поддерживает tie-break по MIC50 и устраняет главное методологическое несоответствие большей части существующей литературы — бинарное описание гемолитической активности там, где фактическая задача требует количественного окна безопасности.

1 6 11 13 17 21 30 57 75 <https://www.nature.com/articles/s42003-025-07615-w>
<https://www.nature.com/articles/s42003-025-07615-w>

2 14 22 53 61 68 <https://www.nature.com/articles/srep22843>
<https://www.nature.com/articles/srep22843>

3 12 15 16 20 24 34 35 51 56 60 <https://www.nature.com/articles/s41598-020-67701-3>
<https://www.nature.com/articles/s41598-020-67701-3>

4 42 <https://pmc.ncbi.nlm.nih.gov/articles/PMC10131225/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC10131225/>

5 48 52 59 <https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0196829>
<https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0196829>

7 8 70 <https://clsi.org/shop/standards/m07/>
<https://clsi.org/shop/standards/m07/>

9 18 <https://pmc.ncbi.nlm.nih.gov/articles/PMC9917735/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9917735/>

10 73 <https://pmc.ncbi.nlm.nih.gov/articles/PMC1855469/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC1855469/>

19 <https://researchprofiles.ku.dk/en/publications/optimization-of-the-hemolysis-assay-for-the-assessment-of-cytotox/>
<https://researchprofiles.ku.dk/en/publications/optimization-of-the-hemolysis-assay-for-the-assessment-of-cytotox/>

- 23 <https://pubmed.ncbi.nlm.nih.gov/28211294/>
<https://pubmed.ncbi.nlm.nih.gov/28211294/>
- 25 76 <https://academic.oup.com/bioinformatics/article/36/11/3350/5799076>
<https://academic.oup.com/bioinformatics/article/36/11/3350/5799076>
- 26 <https://pmc.ncbi.nlm.nih.gov/articles/PMC7538962/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7538962/>
- 27 69 <https://github.com/adibayaseen/HemoNet>
<https://github.com/adibayaseen/HemoNet>
- 28 https://www.researchgate.net/publication/363857498_AMPDeep_hemolytic_activity_prediction_of_antimicrobial_peptides_using_transfer_learning
https://www.researchgate.net/publication/363857498_AMPDeep_hemolytic_activity_prediction_of_antimicrobial_peptides_using_transfer_learning
- 29 <https://arxiv.org/abs/2309.03099>
<https://arxiv.org/abs/2309.03099>
- 31 https://doi.org/10.1002/pro.70087?urlappend=%3Futm_source%3Dresearchgate.net%26utm_medium%3Darticle
https://doi.org/10.1002/pro.70087?urlappend=%3Futm_source%3Dresearchgate.net%26utm_medium%3Darticle
- 32 74 <https://arxiv.org/abs/2507.08162>
<https://arxiv.org/abs/2507.08162>
- 33 <https://pubs.acs.org/doi/10.1021/acssynbio.6c00173>
<https://pubs.acs.org/doi/10.1021/acssynbio.6c00173>
- 36 40 77 <https://www.vendruscolo.ch.cam.ac.uk/camsolmethod.html>
<https://www.vendruscolo.ch.cam.ac.uk/camsolmethod.html>
- 37 43 <https://pubmed.ncbi.nlm.nih.gov/15154768/>
<https://pubmed.ncbi.nlm.nih.gov/15154768/>
- 38 44 <https://pmc.ncbi.nlm.nih.gov/articles/PMC6687799/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC6687799/>
- 39 <https://www.nature.com/articles/s41597-024-03105-6>
<https://www.nature.com/articles/s41597-024-03105-6>
- 41 <https://www.repository.cam.ac.uk/items/4214ecaf-1dee-4dd5-ba6d-d3522a281cb9>
<https://www.repository.cam.ac.uk/items/4214ecaf-1dee-4dd5-ba6d-d3522a281cb9>
- 45 49 <https://academic.oup.com/bib/article/25/4/bbae350/7717956>
<https://academic.oup.com/bib/article/25/4/bbae350/7717956>
- 46 72 <https://link.springer.com/article/10.1186/s13568-016-0295-8>
<https://link.springer.com/article/10.1186/s13568-016-0295-8>
- 47 <https://pmc.ncbi.nlm.nih.gov/articles/PMC10034643/>
<https://pmc.ncbi.nlm.nih.gov/articles/PMC10034643/>
- 50 https://github.com/FrankWanger/ML_Peptide
https://github.com/FrankWanger/ML_Peptide
- 54 55 <https://webs.iiitd.edu.in/raghava/hemopi/datasets.php>
<https://webs.iiitd.edu.in/raghava/hemopi/datasets.php>
- 58 71 <https://www.novoprolabs.com/tools/peptide-solubility-pred>
<https://www.novoprolabs.com/tools/peptide-solubility-pred>

62 <https://github.com/raghavagps/HemoPI2>

<https://github.com/raghavagps/HemoPI2>

63 <https://github.com/Cpillar/ConsAMPHemo>

<https://github.com/Cpillar/ConsAMPHemo>

64 <https://github.com/plissonf/ML-guided-discovery-and-design-of-non-hemolytic-peptides>

<https://github.com/plissonf/ML-guided-discovery-and-design-of-non-hemolytic-peptides>

65 <https://github.com/ChakradharG/PeptideBERT>

<https://github.com/ChakradharG/PeptideBERT>

66 <https://github.com/ur-whitelab/peptide-dashboard>

<https://github.com/ur-whitelab/peptide-dashboard>

67 <https://github.com/lincubator/LysePred>

<https://github.com/lincubator/LysePred>